



4EK211 Základy ekonometrie

Odhad klasického lineárního regresního modelu

Cvičení 2

Metodologický postup tvorby EM

1. Specifikace modelu

- určení proměnných
- určení vzájemných vazeb mezi proměnnými
- formulace hypotéz – v podobě algebraických vztahů (tj. jedné či více rovnic)
- specifikace náhodných vlivů

2. Odhad parametrů (tj. kvantifikace)

- využití disponibilní (tj. výběrové) informace z dat
- použití vhodné odhadové techniky

3. Verifikace

- jak se **odhadnutý model** shoduje s teorií a napozorovanými daty
 - **ekonomická** (jestli proměnné modelu mají správný směr a intenzitu)
 - **statistická** (ověření přesnosti a významnosti výsledků)
 - **ekonometrická** (zda byly dodrženy podmínky pro použití dané odhadové techniky a statistických testů)

4. Využití

- kvalitativní a kvantitativní analýza minulého vývoje
- předpovědi (predikce, prognózy)
- volba hospodářské politiky
 - analýza různých scénářů
 - simulační experimenty
- aplikace na mikroúrovni
 - banky (nesplácení úvěru, odhad ztráty dané nesplácením úvěru, odhad pravděpodobnosti podvodu)
 - marketing (odchod zákazníka, pořízení produktu – cross-sell)
 - cena komodity ve vztahu k poptávanému množství
 - příjem spotřebitele versus cena komodity
 - velikost prodeje versus prostředky na reklamu

Klasický lineární regresní model (KLRM)

Obecný model (maticový zápis)

$$y = X\beta + u$$

- $X =$ matice ($n \times (k+1)$) pozorování exogenních proměnných, včetně 1. sloupce úroňové konstanty
- $y =$ sloupcový vektor ($n \times 1$): n pozorování endogenních proměnných
- $\beta =$ sloupcový vektor ($(k+1) \times 1$) regresních parametrů
- $u =$ sloupcový vektor náhodné složky, $u_i \sim N(0, \sigma^2)$, *iid*
- $k =$ počet vysvětlujících proměnných; $k + 1$: počet regresních parametrů ($k + 1$ jedna úroňová konstanta)
- $n =$ počet pozorování

Zápis KLRM po složkách

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u$$

- za předpokladu: $n > (k+1)$
- odhadnout koeficienty β – tj. určit b (resp. $\hat{\beta}$ - odhady β)

Klasický lineární regresní model (KLRM)

Obečně specifikovaný vs. odhadnutý model

$$y = X\beta \rightarrow y = X\beta + u$$

- model „naplníme“ daty a odhadneme

$$\rightarrow y = Xb + e$$

X , y jsou pozorování, b : odhad parametrů, e : rezidua

$$\rightarrow \hat{y} = Xb$$

kde \hat{y} jsou vyrovnané hodnoty, rezidua jsou rovna 0

Rezidua vs. náhodná složka

rezidua = rozdíl mezi napozorovanými a vyrovnanými hodnotami:

$$e = y - \hat{y}$$

náhodná složka = rozdíl mezi napozorovanými hodnotami a jejich střední hodnotou:

$$u = y - E(y)$$

Klasický lineární regresní model (KLRM)

Bodová odhadová funkce „ b “

- Založena na minimalizaci součtu čtverců
- součet čtverců reziduí: $\mathbf{e}^T \mathbf{e}$
- $\mathbf{b} \dots \sum \mathbf{e}^T \mathbf{e} \rightarrow \min$
- kdy je funkce minimální:
 - první derivace funkce je nulová
 - druhá derivace funkce je kladná
 - fce více proměnných: matice 2. derivací je P.S.D.
- **metoda nejmenších čtverců (MNČ / OLS)**
- funkční předpis odhadové funkce:

$$\mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- poskytuje odhady:
 - **nestranné** (resp. nevychýlené)
 - **vydatné**

$$\mathbf{b}^T = (b_0, b_1, b_2, \dots, b_k)$$

Klasický lineární regresní model (KLRM)

Odvození bodové odhadové funkce vektoru „b“

$$f(\mathbf{b}) \dots \sum \mathbf{e}^T \mathbf{e} \rightarrow \min$$

$$\mathbf{e}^T \mathbf{e} = (\mathbf{y} - \mathbf{X}\mathbf{b})^T (\mathbf{y} - \mathbf{X}\mathbf{b}) = \mathbf{y}^T \mathbf{y} - 2\mathbf{b}^T \mathbf{X}^T \mathbf{y} + \mathbf{b}^T \mathbf{X}^T \mathbf{X} \mathbf{b}$$

$$\frac{\partial \mathbf{e}^T \mathbf{e}}{\partial \mathbf{b}^T} = \frac{\partial (\mathbf{y}^T \mathbf{y} - 2\mathbf{b}^T \mathbf{X}^T \mathbf{y} + \mathbf{b}^T \mathbf{X}^T \mathbf{X} \mathbf{b})}{\partial \mathbf{b}^T} = 0 - 2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \mathbf{b} = 0$$

$$2\mathbf{X}^T \mathbf{y} = 2\mathbf{X}^T \mathbf{X} \mathbf{b}$$

$$(\mathbf{X}^T \mathbf{X}) \mathbf{b} = \mathbf{X}^T \mathbf{y}$$

$$(\mathbf{X}^T \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{X}) \mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

$$\mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Klasický lineární regresní model (KLRM) - příklad

Příklad 1:

$$y_i = (1, 4, 7, 9)$$

$$x_i = (4, 3, 1, 1)$$

$$y_i = \beta_0 + \beta_1 x_i + u_i, i = 1, 2, \dots, 4$$

- stanovte odhad parametrů β_0 a β_1 , aby součet čtverců odchylek vyrovnaných hodnot od hodnot napozorovaných byl minimální
- napište odhadnutou regresní nadrovinu
- vypočítejte vyrovnané hodnoty
- vypočítejte rezidua e_i
- proveďte výpočty v programu MS Excel (využijte maticové počty)
- proveďte výpočty v programu GiveWin2 (s modulem PcGive)
- **řešení:** $b_0 = 31/3 = 10,33$
 $b_1 = -61/27 = -2,26$

Klasický lineární regresní model (KLRM) - příklad

Příklad 2:

$$y_i = (5, 4, 6, 4, 3)$$

$$x_i = (3, 2, 3, 2, 3)$$

$$y_i = \beta_0 + \beta_1 x_i + u_i, i = 1, 2, \dots, 5$$

- stanovte odhad parametrů β_0 a β_1 , aby součet čtverců odchylek vyrovnaných hodnot od hodnot napozorovaných byl minimální
- napište odhadnutou regresní nadrovinu
- vypočítejte vyrovnané hodnoty
- vypočítejte rezidua e_i
- proveďte výpočty v programu MS Excel (využijte maticové počty)
- proveďte výpočty v programu GiveWin (s modulem PcGive)
- **řešení:** $b_0 = 2,67$
 $b_1 = 0,67$

Klasický lineární regresní model (KLRM)

Gaussovy-Markovovy předpoklady

1. $E(\mathbf{u}) = \mathbf{0}$

- náhodné vlivy mají nulovou střední hodnotu (chyba není systematická)

2. $E(\mathbf{u} \mathbf{u}^T) = \sigma^2 \mathbf{I}_n$; n – počet pozorování

- kovarianční matice: rozptyl vícerozměrné náhodné složky
- konečný a konstantní rozptyl na diagonále: homoskedasticita
- náhodné složky jsou sériově (vzájemně) nezávislé: nuly mimo diagonálu (porušení: autokorelace)

3. \mathbf{X} je nestochastická matice $\rightarrow E(\mathbf{X}^T \mathbf{u}) = \mathbf{0}$

- veškerá „náhodnost“ \mathbf{y} pochází z náhodné složky

4. \mathbf{X} má plnou sloupcovou hodnost

- Sloupce matice \mathbf{X} (vysvětlující proměnné modelu vč. Sloupce konstanty) jsou vzájemně lineárně nezávislé $\rightarrow (\mathbf{X}^T \mathbf{X})^{-1}$ existuje
Porušení: perfektní či silná multikolinearita

Klasifikace vlastností odhadových metod:

Vlastnosti bodového odhadu, $n < 30$


- **nestrannost (nevychýlenost / nezkreslenost)** odhadu:

$$E(b) = \beta$$

b – získáme z více výběrových vzorků

pokud $E(b) > \beta$ – odhady jsou nadhodnoceny,


$E(b) < \beta$ – odhady jsou podhodnoceny



Klasifikace vlastností odhadových metod:

Vlastnosti bodového odhadu, $n < 30$


- **vydatnost** odhadu: standardní chyba regresního koeficientu s_b **musí být minimální** ze všech jiných postupů
 - to způsobuje, že intervalové odhady jsou nejmenší
 - jako nevychýlený odhad může sloužit více statistik, z nichž nejvhodnější je ta, která má minimální rozptyl



Klasifikace vlastností odhadových metod:

Vlastnosti bodového odhadu, $n \geq 30$

- **konzistentní** – bodový odhad b je konzistentním odhadem, jestliže jeho hodnota s rostoucím počtem pozorování n konverguje ke skutečnému = populačnímu parametru:
- $p \lim_{n \rightarrow \infty} b = \beta$, tj. pro $n \rightarrow \infty$: $b_j \rightarrow \beta_j \wedge \text{VAR}(b_j) \rightarrow 0$




Pro konzistentní odhadové funkce růst n vede ke zlepšení vlastností odhadu.

Klasifikace vlastností odhadových metod:

Vlastnosti bodového odhadu, $n \geq 30$


- **asymptoticky nestranný** – je to slabší vlastnost, (pokud je odhad konzistentní je vždy také asymptoticky nestranný)
- $p \lim_{n \rightarrow \infty} E(b) = \beta$, tj. pro $n \rightarrow \infty$: $E(b_j) \rightarrow \beta_j \wedge \text{VAR}(b_j) \rightarrow k \neq 0$



Klasifikace vlastností odhadových metod:

Vlastnosti bodového odhadu, $n \geq 30$

- **asymptotická vydatnost** – rozptyl konverguje k nule rychleji než s použitím jiné odhadové funkce



Klasický lineární regresní model (KLRM)

Vlastnosti bodového odhadu – maticové odvození

- Mějme KLRM: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$; $\mathbf{u} \sim N(\mathbf{0}; \sigma^2 \mathbf{I}_n)$
- Východisko pro popis teoretických vlastností (střední hodnoty a rozptylu) odhadové funkce MNČ:

$$\mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad \text{odhadová funkce MNČ}$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T (\mathbf{X}\boldsymbol{\beta} + \mathbf{u}) \quad \text{dosadili jsme } \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u} \quad \text{roznásobena závorka}$$

$$= \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u}$$

výsledný tvar po eliminaci:
 $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} = \mathbf{I}_{n \times n}$.

Tento tvar je vhodný pro další popis vlastností MNČ.

Klasický lineární regresní model (KLRM)

Nestrannost bodového odhadu MNČ

$$\mathbf{b} = \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u}$$

Obě strany výchozí rovnice vyjádříme jako střední hodnoty:

$$E(\mathbf{b}) = E(\boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u})$$

Pro N.V. A a B platí: $E(A + B) = E(A) + E(B)$.
Protože $\boldsymbol{\beta}$ je vektor skutečných (deterministických ale přímo nepozorovatelných) parametrů, lze psát $E(\boldsymbol{\beta}) = \boldsymbol{\beta}$:

$$= \boldsymbol{\beta} + E[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u}]$$

\mathbf{X} je deterministická matice, opět můžeme využít $E(\mathbf{X}) = \mathbf{X}$ a přepíšeme:

$$= \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T E(\mathbf{u})$$

V KLRM je střední hodnota náhodné složky nulová /nulový vektor/.

Pro $E(\mathbf{u}) = \mathbf{0}$:

$$= \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{0}$$

Je zřejmé, že při násobení nulovým vektorem platí: $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{0} = \mathbf{0}$. Proto:

$$E(\mathbf{b}) = \boldsymbol{\beta}$$

Neboli, odhadová fce MNČ je nestranná (při dodržení uvedených podmínek, resp. Gaussových-Markovových předpokladů).

Klasický lineární regresní model (KLRM)

Rozptyl bodového odhadu MNČ

$$\mathbf{b} = \boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u}$$

$$\text{VAR}(\mathbf{b}) = \text{VAR}(\boldsymbol{\beta} + (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u})$$

$$= \text{VAR}[(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{u}]$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \text{VAR}(\mathbf{u}) [(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T]^T$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \sigma^2 \mathbf{I}_n [(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T]^T$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \sigma^2 \mathbf{I}_n \mathbf{X} [(\mathbf{X}^T \mathbf{X})^{-1}]^T$$

$$= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \sigma^2 \mathbf{I}_n \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}$$

$$= \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1}$$

$$\text{VAR}(\mathbf{b}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$$

Výchozí rovnici vyjádříme pro rozptyl:

Protože $\boldsymbol{\beta}$ je vektor deterministických (fakticky konstantních) parametrů, $\text{VAR}(\boldsymbol{\beta}) = \mathbf{0}$:

Analogicky k $\text{VAR}(cX) = c^2 \text{VAR}(X)$ pro konstantu c a N.V. X , konstruujeme maticovou „kvadratickou formu“ typu: $\text{VAR}(\mathbf{A}\mathbf{v}) = \mathbf{A} \text{VAR}(\mathbf{v}) \mathbf{A}^T$, kde \mathbf{A} je deterministická matice a \mathbf{v} je vektor N.V.:

Pro rozptyl *iid* náhodné složky v KLRM platí $\text{VAR}(\mathbf{u}) = \sigma^2 \mathbf{I}_n$:

Výraz v hranaté závorce upravíme pomocí věty o transpozici součinu matic: $(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$

Protože $\mathbf{X}^T \mathbf{X}$ je symetrická matice, pro $(\mathbf{X}^T \mathbf{X})^{-1}$ platí: $[(\mathbf{X}^T \mathbf{X})^{-1}]^T = (\mathbf{X}^T \mathbf{X})^{-1}$.

\mathbf{I}_n vypustíme (násobení jednotkovou maticí nemá vliv na výsledek). Protože $c \mathbf{A} = \mathbf{A} c$, lze rozptyl σ^2 (číslo) předsunout ve výrazu před matice:

Protože $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} = \mathbf{I}_n$, tento výraz opět vypustíme:

Je kovarianční matice udávající rozptyl vektoru \mathbf{b} (vektor bodových odhadů b_j).

Klasický lineární regresní model (KLRM)

Rozptyl bodového odhadu MNČ

- Pro KLRM: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}$; $\mathbf{u} \sim N(\mathbf{0}; \sigma^2 \mathbf{I}_n)$ tedy platí:

$$\mathbf{b} \sim N(\boldsymbol{\beta}; \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}) \quad \dots \text{při odhadu MNČ}$$

- Protože neznáme skutečný rozptyl u_j (resp. nepozorovatelné náhodné složky \mathbf{u}), tj.: σ^2 , pracujeme s odhadnutým rozptylem, vypočteným pomocí reziduální složky odhadnutého modelu:

$$\text{odh. } \sigma^2 = s^2 = \frac{1}{n-k-1} \sum_{i=1}^n e_i^2 = \frac{\mathbf{e}^T \mathbf{e}}{n-k-1}$$

kde $n-k-1$: počet stupňů volnosti odhadu MNČ,
 n : počet pozorování,
 $k+1$: počet regresních parametrů LRM (včetně konst.)