

4EK211 Základy ekonometrie

Odhad klasického lineárního regresního modelu III

Cvičení 4

Jednoduchý KLRM – funkční formy a interpretace β_1

- Pro jednoduchý LRM v základním tvaru $Y_i = \beta_0 + \beta_1 X_i + u_i$, platí:

Přehled funkčních forem při použití logaritmické transformace dat

Model	Endogenní proměnná	Exogenní proměnná	Interpretace β_1
Lineární (level-level)	Y_i	X_i	$E(\Delta Y_i) = \beta_1 \Delta X_i$
Lineárně logaritmický (level-log)	Y_i	$\ln(X_i)$	$E(\Delta Y_i) = (\beta_1/100)\% \Delta X_i$
Logaritmicko lineární (log-level)	$\ln(Y_i)$	X_i	$E(\% \Delta Y_i) = (100\beta_1) \Delta X_i$
Dvojlogaritmický (log-log)	$\ln(Y_i)$	$\ln(X_i)$	$E(\% \Delta Y_i) = \beta_1 \% \Delta X_i$

kde $E(\Delta Y_i)$ je očekávaná změna Y_i a $E(\% \Delta Y_i)$ je očekávaná procentní změna Y_i

Jednoduchý KLRM – funkční formy a interpretace β_1

Příklad 1 (odhadnutý KLRM):

$$\ln(\mathbf{wage}_i) = 0,584 + 0,083 \mathbf{educ}_i$$

kde \mathbf{wage} je měsíční mzda v USD

\mathbf{educ} - vzdělání (ukončené roky standardního studia)

Interpretace:

- Každý ukončený rok studia zvýší očekávané (vyrovnané) příjmy o $(100 \cdot 0,083)\%$, tj. o 8,3%.
- **POZOR:** Efekt získaného „titulu“ (maturita, tituly Bc., Ing.): uvažujeme-li systematický mzdový bonus za získaný titul, není mzdový přínos stejný u všech roků standardního studia. Obvykle řešíme zahrnutím umělých proměnných do modelu: získání/nezískání titulu vyjádříme pomocí nové proměnné typu 1-0 (logická proměnná, kvalitativní exogenní informace). Očekávaný mzdový efekt titulu pak bude vyjádřen příslušným koeficientem β_j u umělé proměnné.

Jednoduchý KLRM – funkční formy a interpretace β_1

Příklad 2 (odhadnutý KLRM):

$$\ln(\mathbf{CEO}wage_i) = 4,822 + 0,257 \ln(\mathbf{sales}_i)$$

kde $\mathbf{CEO}wage$ je roční mzda ředitele (CEO) sledované firmy, měřeno v tis. USD.

\mathbf{sales} - roční obrat (prodeje) sledované firmy, měřeno v milionech USD.

Interpretace:

- Jednoprocentní růst prodejů firmy zvýší očekávané (průměrné, vyrovnané) příjmy ředitele (CEO) o 0,257 %.

Pozn: Interpretace parametrů je smysluplná a platí pro verifikované modely (ekonomicky, statisticky, ekonometricky)

Různé specifikace KLRM – srovnání, testování hypotéz

Kvalita regresního modelu závisí na dvou hlavních faktorech:

- **Shoda modelu s daty** (vysoké R^2 , model významný jako celek)
- **Jednoduchost** (Occamova břitva, počet stupňů volnosti, praktická využitelnost).
- **Zde popsaná srovnání dvou (a více) KLRM mají smysl pouze pro danou (jednu) endogenní proměnnou:**
- **Příklad:** „Kvalitu“ LRM ve tvaru:

$$wage_i = \beta_0 + \beta_1 educ_i + u_i$$

Ize přímo srovnat s tvarem:

$$wage_i = \beta_0 + \beta_1 educ_i + \beta_2 exper_i + u_i$$

ale nikoliv s LRM:

$$\ln(wage_i) = \beta_0 + \beta_1 educ_i + u_i$$

Různé specifikace KLRM – srovnání, testování hypotéz

Jednoduchost KLRM je nepřímo úměrná počtu proměnných KLRM: k

Ukazatele, které poměřují shodu s daty vůči jednoduchosti modelu:

- **Ke srovnání různých specifikací modelu lze použít:**
 - Korigovaný koeficient vícenásobné determinace \bar{R}^2
 - Informační kritéria (např.: *AIC*, *SIC*, *HQIC*, atd.)
- **Testování (sdružené) hypotézy o parametrech β_j**
 - *F*-test pro nulová omezení parametrů β_j
(speciální případ lineárního omezení)
 - *F*-test pro lineární omezení parametrů β_j

- **Korigovaný koeficient vícenásobné determinace**

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-(k+1)}$$

kde:

$$R^2 = \frac{VS\check{C}}{CS\check{C}} = 1 - \frac{NS\check{C}}{CS\check{C}} \quad ; \quad R^2 \in \langle 0, 1 \rangle \quad ; \quad NS\check{C} = \sum (Y_i - \hat{Y}_i)^2 \quad ; \quad CS\check{C} = \sum (Y_i - \bar{Y})^2$$

- Zatímco R^2 nikdy neklesne přidáním další vysvětlující proměnné do modelu, \bar{R}^2 poklesnout může: v důsledku přidání málo významné exogenní proměnné (\bar{R}^2 může nabývat i záporných hodnot).
- Rozhodovací kritérium: maximalizujeme hodnotu \bar{R}^2 .

Různé specifikace KLRM – srovnání, testování hypotéz

- **Korigovaný koeficient vícenásobné determinace: PŘÍKLAD**

Máme LRM ve tvaru:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i \quad ; \quad n = 20 \quad (1)$$

Odhadnutý model má $R^2 = 0,8$ a je významný z hlediska t -testů i F -testu.

- (2) Ke specifikaci (1) přidám vysvětlující proměnnou X_4 a tím zvýším R^2 na hodnotu 0,82.
- (3) Alter.: ke specifikaci (1) přidám exogenní proměnnou Z_1 a tím zvýším R^2 na hodnotu 0,81.

Podle hodnot koeficientu \bar{R}^2 vyberte ze tří variant (1), (2) a (3) „nejlepší“ specifikaci LRM pro proměnnou Y_i .

(Řešení: 0,762 vs. 0,772 vs. 0,759)

Různé specifikace KLRM – srovnání, testování hypotéz

Informační kritéria

- Charakterizují závislost shody modelu s daty na počtu vysvětlujících proměnných zahrnutých do modelu (podobně jako \bar{R}^2).
- U informačních kritérií (IC) je shoda modelu s daty obvykle dána pomocí NSČ (RSS) a jednoduchost (resp. složitost) modelu se řídí počtem regresních proměnných k .
- **POZOR NA DATA MINING:** výběr ekonometrických modelů by měl být založen primárně na ekonomické teorii a teprve v druhé řadě na ukazatelích jako \bar{R}^2 nebo IC.
Cílem ekonometrické analýzy má být získání smysluplných odhadů (pro prognózy, rozhodování, analýzy), které odpovídají ekonomické teorii.

Akaikeho informační kritérium (AIC)

- $$AIC = \left(\frac{2k}{n} \right) + \ln \left(\frac{RSS}{n} \right), \text{ alternativně: } AIC = e^{\frac{2k}{n}} \cdot \frac{RSS}{n}$$

kde: RSS je součet čtverců reziduí regrese (NSČ),

n - počet pozorování,

k - počet vysvětlujících proměnných modelu.

- **Srovnávat lze jen modely pro danou (jednu) endogenní proměnnou.**
- Vybereme takovou specifikaci (zvolíme sadu exogenních proměnných), pro kterou je spočtená hodnota AIC minimální. Pravidlo platí pro logaritmický i exponenciální tvar AIC .
- AIC je vhodné jen pro modely s úroňovou konstantou.

Schwarzovo informační kritérium (SIC)

- $$SIC = \frac{k}{n} \ln(n) + \ln\left(\frac{RSS}{n}\right), \text{ alternativně: } SIC = n^{\frac{k}{n}} \cdot \frac{RSS}{n}$$

kde: RSS je součet čtverců reziduí regrese (NSČ),

n - počet pozorování,

k - počet vysvětlujících proměnných modelu.

- **Srovnávat lze jen modely pro danou (jednu) endogenní proměnnou.**
Kritérium: minimalizujeme SIC . Použití SIC je vhodné jen pro modely s úrovnovou konstantou.
- SIC penalizuje zahrnutí dodatečných vysvětlujících proměnných více než AIC : je tedy „přísnější“ (nemusí být „lepší“).
- Nejčastěji používaným IC je AIC .

Různé specifikace KLRM – srovnání, testování hypotéz

- F -test významnosti LRM jako celku je založen na testovací statistice:

$$F = \frac{R^2}{1 - R^2} \frac{n - (k + 1)}{k} \bigg|_{H_0} \sim F(k, n - k - 1)$$

Pro H_0 : R^2 se statisticky významně neliší od nuly,
altern.: LRM jako celek je statisticky nevýznamný,
altern.: $\beta_1 = \dots \beta_k = 0$; LRM dán pouze úrovnovou konstantou β_0 .

H_1 : R^2 se statisticky významně liší od nuly,
alt.: LRM jako celek je statisticky významný.

$F > F^*_{(k, n-k-1)}$... zamítáme H_0 ve prospěch H_1

$F \leq F^*_{(k, n-k-1)}$... nezamítáme H_0

- Jde o speciální užití obecnějšího testu: **F -test na omezení parametrů**.
 - F -test významnosti LRM jako celku klade **k** omezení na parametry: $\beta_1 = \dots \beta_k = 0$. „Omezen“ zde není pouze parametr β_0 .
 - „Neomezená rovnice“, tj. testovaný LRM se všemi proměnnými a parametry má **$(n-k-1)$** stupňů volnosti.
 - odtud rozdělení F -poměru s (k) a $(n-k-1)$ stupni volnosti.

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-test na nulová a lineární omezení parametrů :**

$$F = \frac{(RSS_r - RSS_u)}{q(RSS_u)} (n - k - 1) \bigg|_{H_0} \sim F(k, n - k - 1)$$

kde RSS_u je nevysvětlený součet čtverců (NSČ) **neomezené regrese** (unrestricted regression),

RSS_r – NSČ omezené regrese (restricted regression),

q – počet omezení na parametry (v omezené regresi),

$(n-k-1)$ – počet stupňů volnosti **v neomezené regresi**,

F – má rozdělení $F(q, n-k-1)$

- Pro vhodně formulované hypotézy H_0, H_1 platí:

$F > F^*_{(k, n-k-1)}$... zamítáme H_0 ve prospěch H_1

$F \leq F^*_{(k, n-k-1)}$... nezamítáme H_0

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-test na nulová omezení parametrů – PŘÍKLAD:**

1. Máme LRM (výchozí, tzv. **neomezený tvar**):

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + u_i$$

Pro $n=158$ je tento LRM model odhadnut (jako významný) a máme spočteno $RSS_u = 1\,181$.

2. Formulujeme hypotézu $H_0: \beta_2 = \beta_3 = 0$; proti $H_1: \neg H_0$ (máme dvě nulová omezení). **Omezený tvar, který odpovídá H_0 :**

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_4 X_{4i} + u_i$$

Na identické sadě pozorování odhadneme omezený LRM.
 $RSS_r = 3\,128$.

Pozn.: $RSS_r \geq RSS_u$; analogicky vždy platí: $R_r^2 \leq R_u^2$

Pozn.: omezený tvar je v tomto případě tzv. **zahnížděný (nested)**, tvoří speciální případ neomezeného tvaru pro $\beta_2 = 0$ a $\beta_3 = 0$.

Klasický lineární regresní model - verifikace

- **F-test na nulová omezení parametrů – PŘÍKLAD (dokončení):**

3. Spočítáme *F-poměr* podle vzorce:

$$F = \frac{(3128 - 1811)}{2(1811)} (158 - 4 - 1) \cong 126$$

Kritická hodnota rozdělení: $F^*(2, 153) = 3,05 \dots$ (pro $\alpha = 0,05$)

4. Vyhodnocení:

Protože $F > F^*$, zamítám H_0 ve prospěch H_1

5. Interpretace:

Hypotéza H_0 je odmítnuta jako neplatná, protože statisticky významně zhoršuje vlastnosti LRM. Omezený model významně hůře postihuje variabilitu endogenní proměnné ve srovnání s neomezeným LRM.

Pozn.: Pokud by u našeho příkladu H_0 platila („byla správná“): v takovém případě nárůst NSČ u omezeného modelu je nevýznamný a F poměr se pohybuje v rozmezí: $<0 ; 3,05>$.

Klasický lineární regresní model - verifikace

- **F-test na lineární omezení parametrů :**

Výchozí **neomezený tvar** LRM může být dán například takto:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

Kromě nulových omezení existují další **základní typy** lineárních omezení, která lze testovat pomocí F-testu:

- $H_0: \beta_1 = \beta_2$
 $H_1: \neg H_0$ nebo $H_1: \beta_1 < \beta_2$ nebo $H_1: \beta_1 > \beta_2$
- $H_0: \beta_1 = 1 - \beta_2$
 $H_1: \neg H_0$ nebo $H_1: \beta_1 < 1 - \beta_2$ nebo $H_1: \beta_1 > 1 - \beta_2$
- $H_0: \beta_1 = 2,7$ (konstanta)
 $H_1: \neg H_0$ nebo $H_1: \beta_1 < 2,7$ nebo $H_1: \beta_1 > 2,7$

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-test na omezení typu $H_0: \beta_1 = \beta_2$:**

Výchozí **neomezený tvar** LRM může být dán například takto:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

Omezený tvar (na základě předpokladu $\beta_1 = \beta_2$) sestavíme:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_1 X_{2i} + \beta_3 X_{3i} + u_i$$

lze psát jako :

$$Y_i = \beta_0 + \beta_1 (X_{1i} + X_{2i}) + \beta_3 X_{3i} + u_i$$

resp. dosazením $Z_i = (X_{1i} + X_{2i})$

získáme výsledný omezený tvar :

$$Y_i = \beta_0 + \beta_1 Z_i + \beta_3 X_{3i} + u_i$$

Odhadneme omezený i neomezený LRM, spočteme jejich NSČ a srovnáme získaný F -poměr s kritickou hodnotou $F^*(1, n-k-1)$

Různé specifikace KLRM – srovnání, testování hypotéz

- Alternativa k F -testu na omezení typu $H_0: \beta_1 = \beta_2$:

Hypotézu H_0 lze přeformulovat na $H_0: \beta_1 - \beta_2 = 0$ a vyhodnotit pomocí t -poměru:

$$t = \frac{b_1 - b_2}{s.e.(b_1 - b_2)}$$

kde :

$$s.e.(b_1 - b_2) = \sqrt{VAR(b_1) + VAR(b_2) - 2COV(b_1, b_2)}$$

Obvyklým způsobem srovnáme t -poměr s kritickou hodnotou $t^*(n-k-1)$ pro zvolenou hladinu významnosti (jednostranný či oboustranný test).

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-test na omezení typu $H_0: \beta_1 = 1 - \beta_2$:**

Výchozí **neomezený tvar** LRM může být dán například takto:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

Omezený tvar (na základě předpokladu $\beta_1 = 1 - \beta_2$) sestavíme:

$$Y_i = \beta_0 + \beta_1 X_{1i} + (1 - \beta_1) X_{2i} + \beta_3 X_{3i} + u_i$$

lze psát jako :

$$Y_i = \beta_0 + \beta_1 X_{1i} + X_{2i} - \beta_1 X_{2i} + \beta_3 X_{3i} + u_i$$

sdružíme podle β_1 :

$$Y_i = \beta_0 + \beta_1 (X_{1i} - X_{2i}) + X_{2i} + \beta_3 X_{3i} + u_i$$

dosadíme $W_i = (X_{1i} - X_{2i})$

$$Y_i = \beta_0 + \beta_1 W_i + X_{2i} + \beta_3 X_{3i} + u_i$$

X_{2i} nemá parametr β a porušuje tvar LRM, proto :

$$(Y_i - X_{2i}) = Y_i^* = \beta_0 + \beta_1 W_i + \beta_3 X_{3i} + u_i$$

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-test na omezení typu $H_0: \beta_1 = 1 - \beta_2$ (dokončení):**

Odhadneme výsledný **omezený tvar** LRM:

$$Y_i^* = \beta_0 + \beta_1 W_i + X_{2i} + \beta_3 X_{3i} + u_i$$

Spočítáme NSČ pro omezený a neomezený tvar a srovnáme získaný F -poměr s kritickou hodnotou $F^*(1, n-k-1)$.

Aby bylo možné porovnat NSČ neomezeného a omezeného modelu, odhadujeme oba tvary vždy na identické sadě pozorování!

- Platí i v tomto případě: Y_i^* a W_i jsou jednoznačně dány původními pozorováními neomezeného tvaru LRM.

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-test na omezení typu $H_0: \beta_1 = 2,7$ (konstanta):**

Výchozí **neomezený tvar** LRM může být dán například takto:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

Omezený tvar (na základě předpokladu $\beta_1 = 2,7$) sestavíme:

$$Y_i = \beta_0 + 2,7 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

X_{1i} nemá parametr β - nelze zde odhadovat MNČ

Protože X_{1i} porušuje tvar pro LRM, upravíme :

$$(Y_i - 2,7 X_{1i}) = Y_i^* = \beta_0 + \beta_2 X_{2i} + \beta_3 X_{3i} + u_i$$

Nakonec opět spočítáme NSČ pro omezený i neomezený tvar a srovnáme získaný F -poměr s kritickou hodnotou $F^*(1, n-k-1)$.

Různé specifikace KLRM – srovnání, testování hypotéz

- **F-testy na omezení parametrů v GRETlu:**

Tento typ testů je do GRETlu zabudovaný:

- Okno s výstupem odhadu: Tests → Linear restrictions

Testovaná omezení se zadávají formou rovnice:

Obecně:

- $H_0: \beta_1 = 0$
- $H_0: \beta_1 = 2,7$ (konstanta)
- $H_0: \beta_1 = \beta_2$
- $H_0: \beta_1 = 1 - \beta_2$
- $H_0: \beta_1 = 1 - 2\beta_2$

GRETl

- $b[vn1] = 0$
- $b[vn1] = 2,7$
- $b[vn1] - b[vn2] = 0$
- $b[vn1] + b[vn2] = 1$
- $b[vn1] + 2*b[vn2] = 1$

kde $vn1$ a $vn2$ zastupují názvy proměnných u parametrů β_1 a β_2